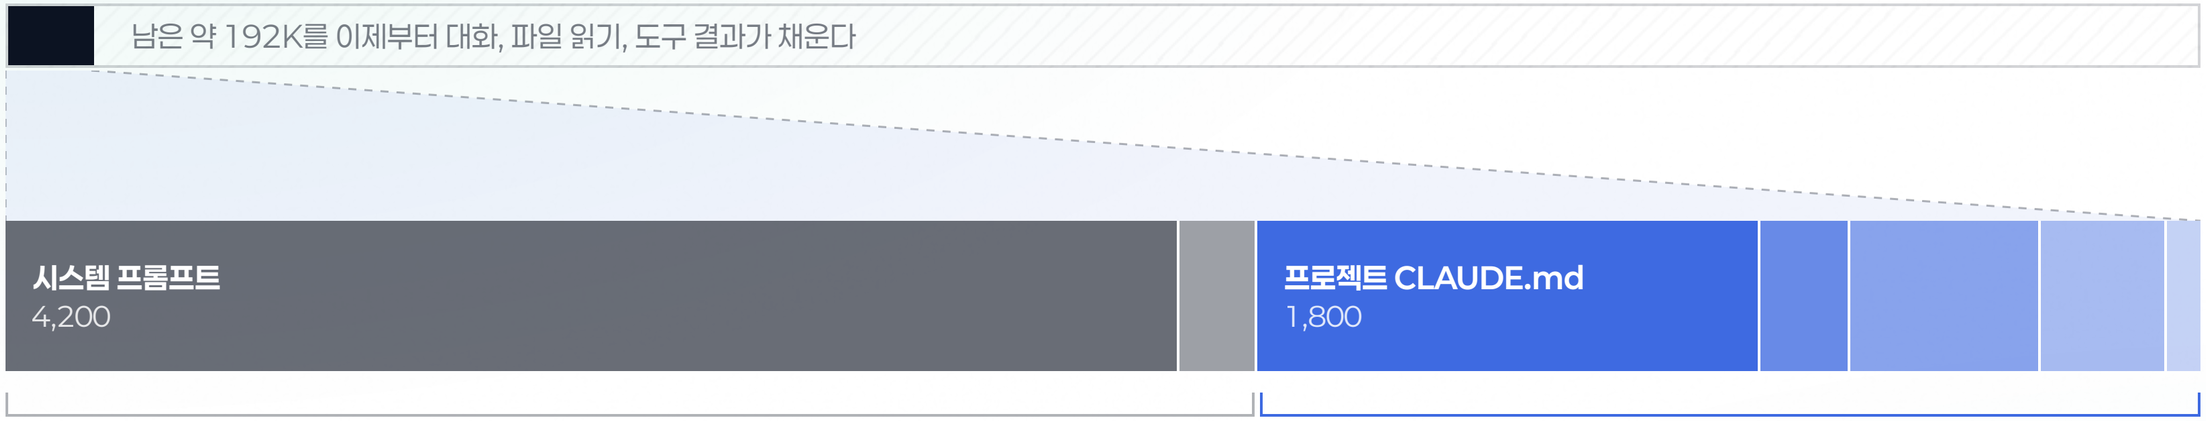
01 컨텍스트

> 모델은 창 안에 있는 것만 안다.
> 그래서 무엇을 넣고, 빼고, 파일로 남길지 설계해야 한다.

컨텍스트 창

“ 아무것도 입력하기 전에, 창에는 이미 약 8천 토큰이 들어 있다

200K 토큰 창 · 세션 시작 직후



Claude Code 기본 4,480

작동 규칙과 환경 정보. 사용자는 보지 못하지만 매번 들어간다.

내가 설계하는 부분 3,370

- 프로젝트 CLAUDE.md 1,800
- 개인 CLAUDE.md 320
- auto memory 680
- 스킬 설명 450
- MCP 도구 이름 120

직접 확인: `/context` · 수치는 Claude Code 공식 문서 “Explore the context window”의 예시값 (환경 정보 280 포함, 설정마다 다름)

Context rot

> **창의 크기는 넣을 수 있는 양이지, 잘 쓸 수 있는 양이 아니다**

같은 질문, 다른 입력	입력 길이 (같은 축척)	정답률
Focused 질문에 필요한 대화만	약 300 토큰	▲ 높음
Full 대화 기록 전체	약 113,000 토큰	▼ 낮음

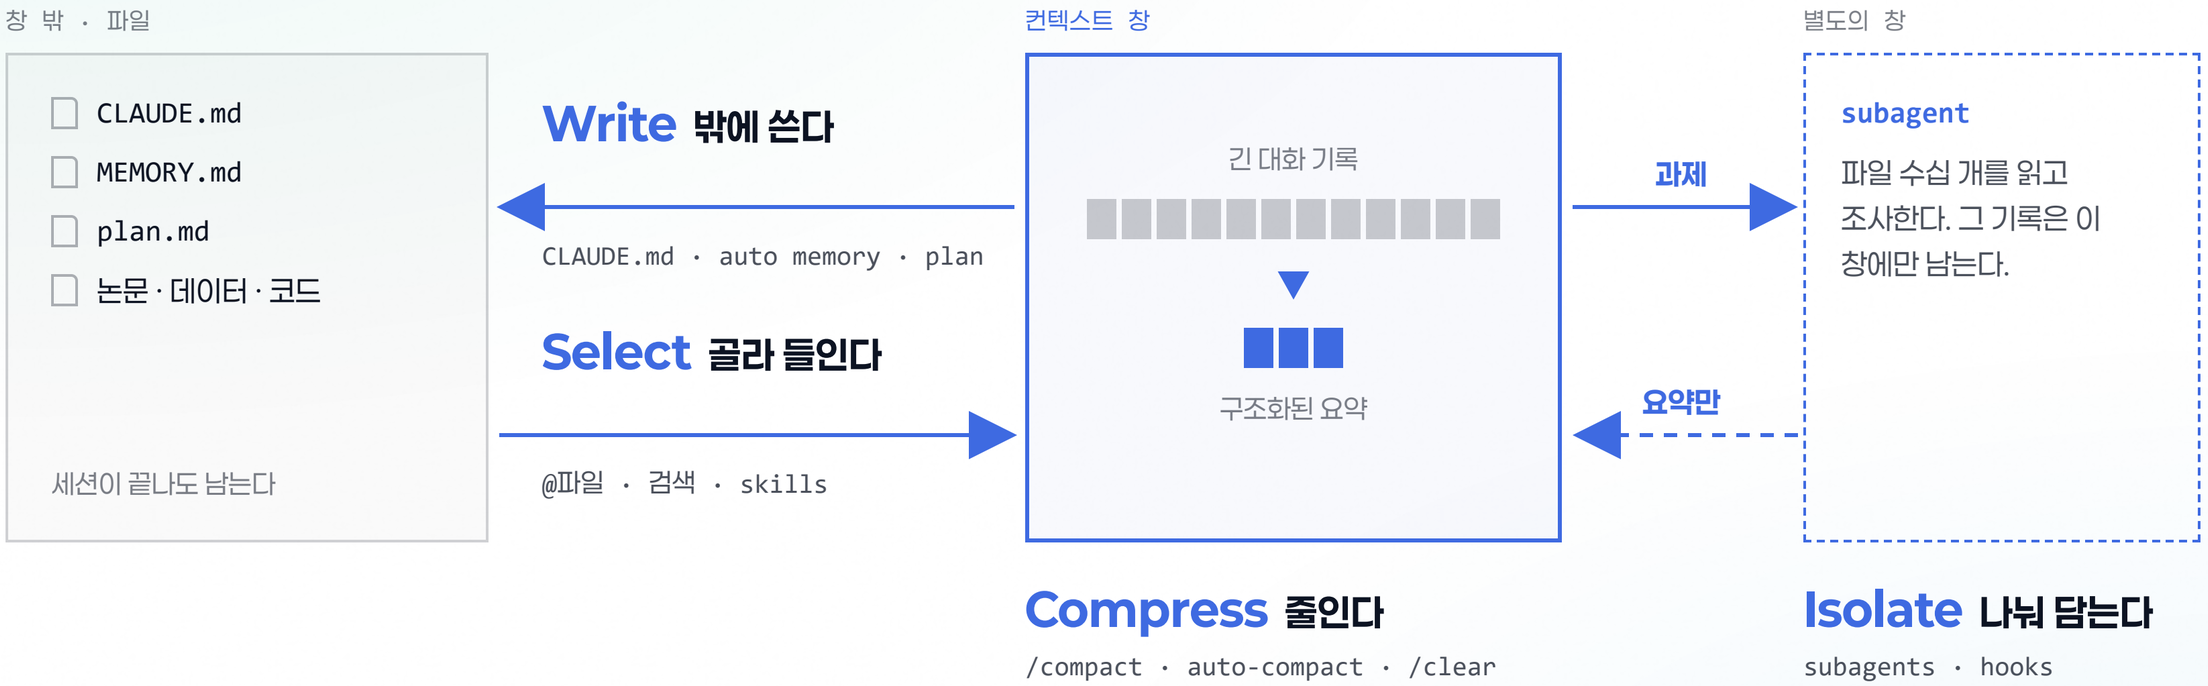
장기 대화 기억 과제(LongMemEval)에서, 실험한 모든 모델이 짧게 골라 준 입력에서 훨씬 잘 답했다.

- **방해 문장 하나**
  정답과 비슷한 방해 문장이 하나만 섞여도 정답률이 떨어진다.
- **표현이 다를수록**
  질문과 정답의 표현이 멀수록, 입력이 길어질 때 더 빨리 무너진다.
- **18개 모델**
  GPT-4.1, Claude 4, Gemini 2.5, Qwen3 등. 입력이 길어지면 성능이 고르게 유지되지 않았다.

출처: Hong, Troynikov, Huber (2025). Context Rot: How Increasing Input Tokens Impacts LLM Performance. Chroma Technical Report.

네 가지 전략

“ 창은 작게 두고, 나머지는 창 밖에서 관리한다



분류: Lance Martin (LangChain, 2025) “Context Engineering for Agents”의 Write · Select · Compress · Isolate. Claude Code 기능 대응은 공식 문서 기준.