CHAPTER 01

CONTEXT

대규모 언어 모델(LLM)이 응답을 생성할 때
입력에 포함되는 토큰의 집합

Anthropic (2025)

CONTEXT WINDOW

컨텍스트 창

모델이 한 번의 호출에서 입력으로 받을 수 있는 토큰의 최대 범위

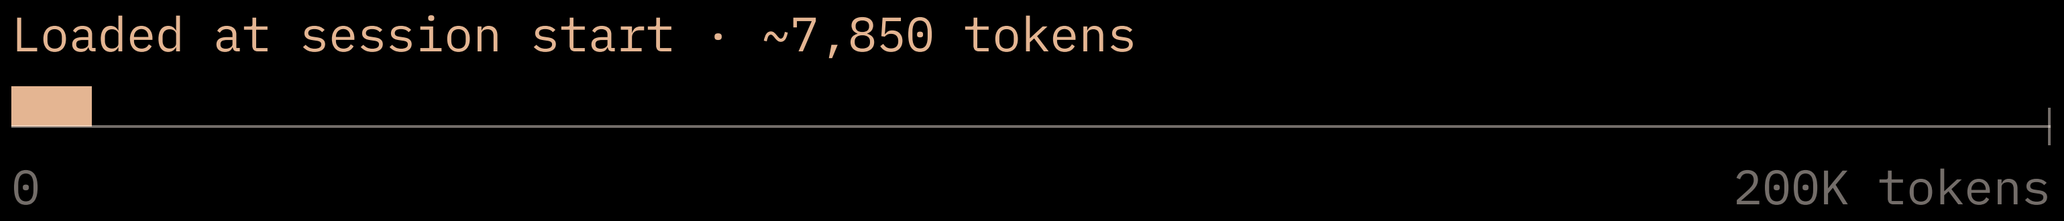

Claude Code Docs · 예시값

긴 컨텍스트에서의 성능 저하

CONTEXT ROT

창 안의 토큰 수가 늘어날수록,
모델이 그 안의 정보를 정확하게 회상하는 능력이 떨어지는 현상

Anthropic (2025) · Hong et al. (2025)

컨텍스트 엔지니어링

CONTEXT ENGINEERING

추론 중 모델에 들어가는 최적의 토큰 집합을 선별하고 유지하는 전략

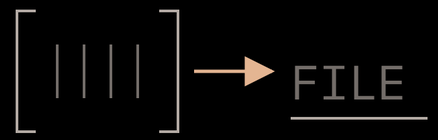

WRITE

창 밖, 파일에
기록한다

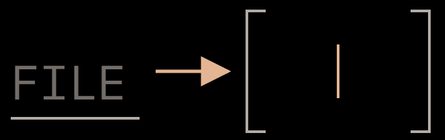

SELECT

필요한 것만
창으로 불러온다

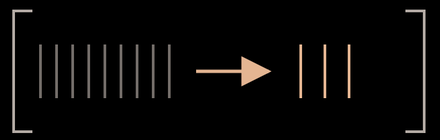

COMPRESS

창 안의 기록을
줄인다

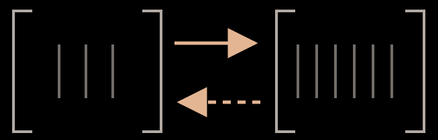

ISOLATE

작업을 별도의
창으로 나눈다

Anthropic (2025) · Martin (2025)