컨텍스트(Context)

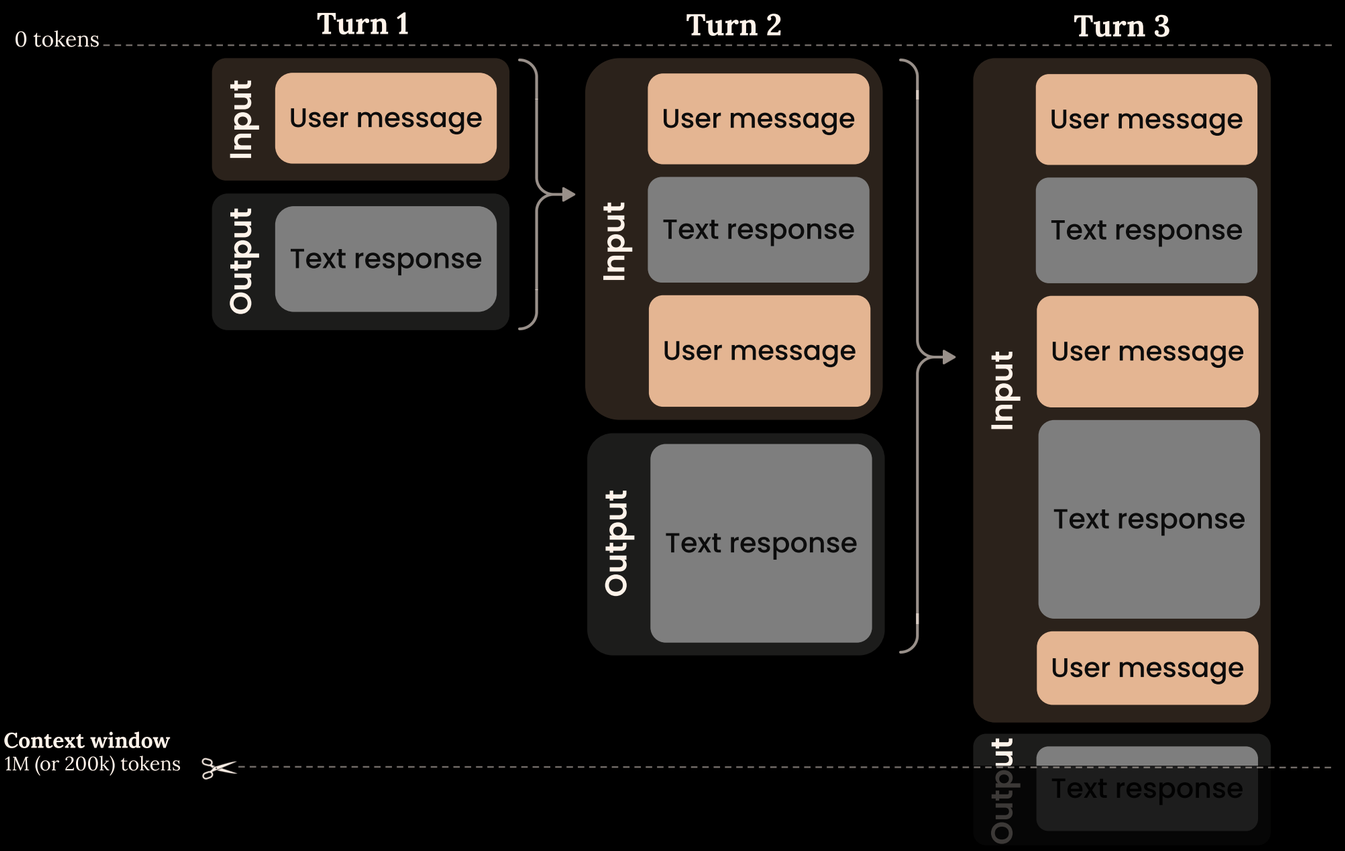
컨텍스트: LLM이 출력을 생성할 때 참조하는 토큰의 집합.

입력과 지금까지 생성한 출력을
모두 포함한다.

구성: 시스템 프롬프트, 도구 정의,
메시지(파일·도구 결과 포함),
모델의 출력

학습 데이터가 아니라, **이번 호출에 넣어 준 토큰만** 본다.

※ 토큰(Token): 모델이 처리하는
최소 단위 (영어 약 3.5자 = 1토큰)



턴마다 입력·출력 누적, 컨텍스트 증가

컨텍스트 창(Context window)

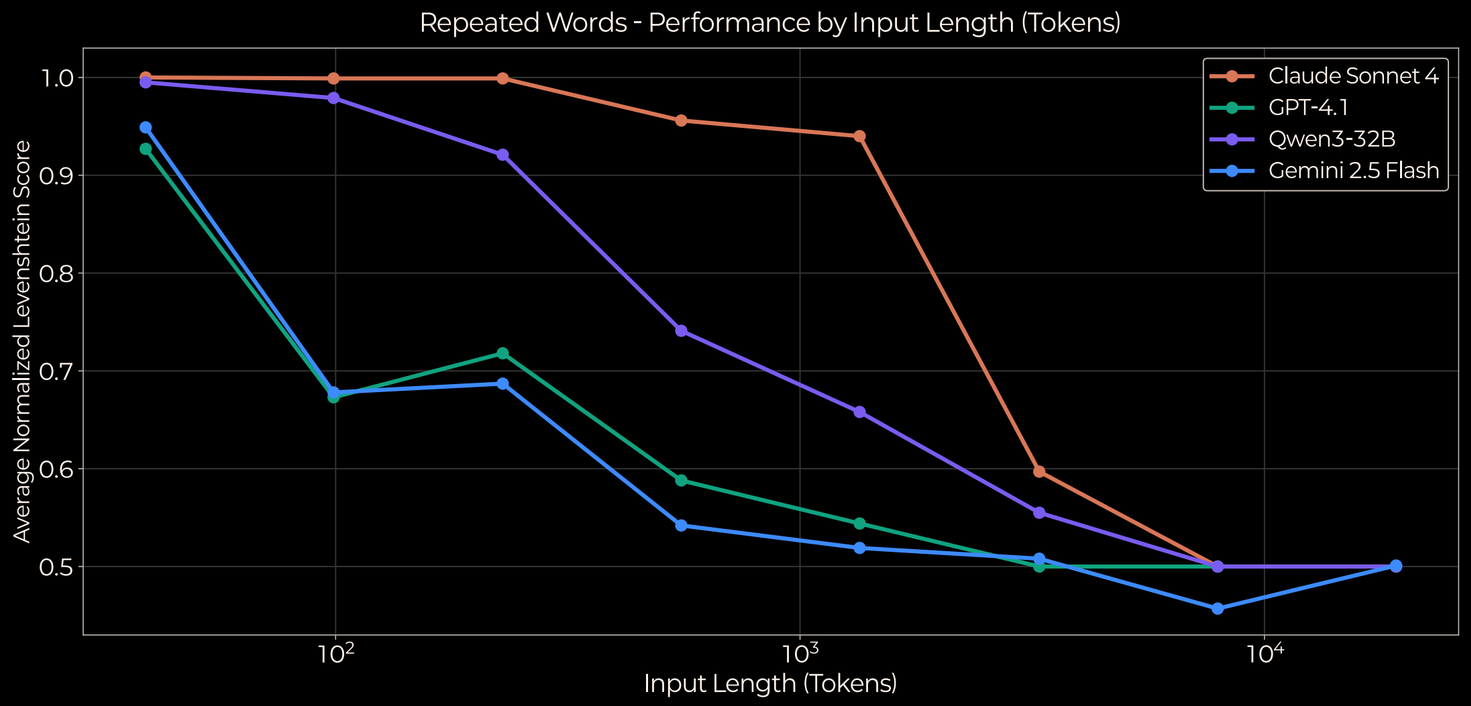
컨텍스트 창: 모델이 새 텍스트를 생성할 때 참조할 수 있는 텍스트의 양.

모델의 작업 기억.
입력과 출력의 합이 **200K 또는 1M 토큰**을 넘을 수 없다.

※ 1M: Opus·Sonnet 4.6 이후
※ 200K: Sonnet 4.5, Haiku 4.5 등

컨텍스트 부패(Context rot):
토큰이 늘수록 정확도와 회상이 떨어지는 현상

※ 어텐션(Attention): 토큰 간 관련성을 따져 중요한 곳에 집중하는 장치.
토큰이 많을수록 분산된다.



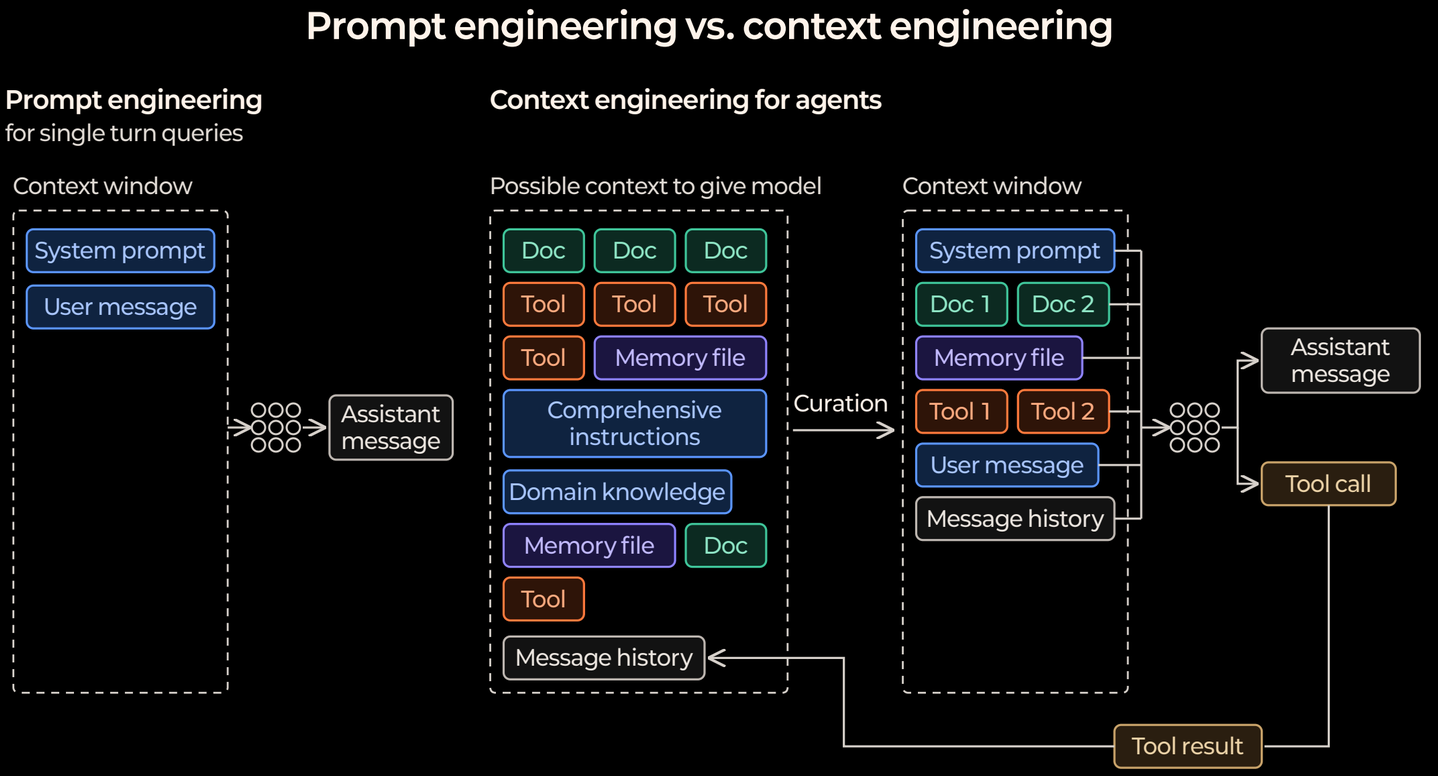
입력 토큰 증가에 따라 모든 모델의 점수 하락

컨텍스트 엔지니어링(Context engineering)

컨텍스트 엔지니어링: 모델이 답을 만드는 동안 창에 넣을 정보를 골라 관리하는 방법.

작업이 이어질수록 읽은 파일과 도구 결과가 창에 쌓인다. 그대로 두면 창이 차고 정확도가 떨어지므로, 매번 **무엇을 넣고 뺄지 골라야** 한다.

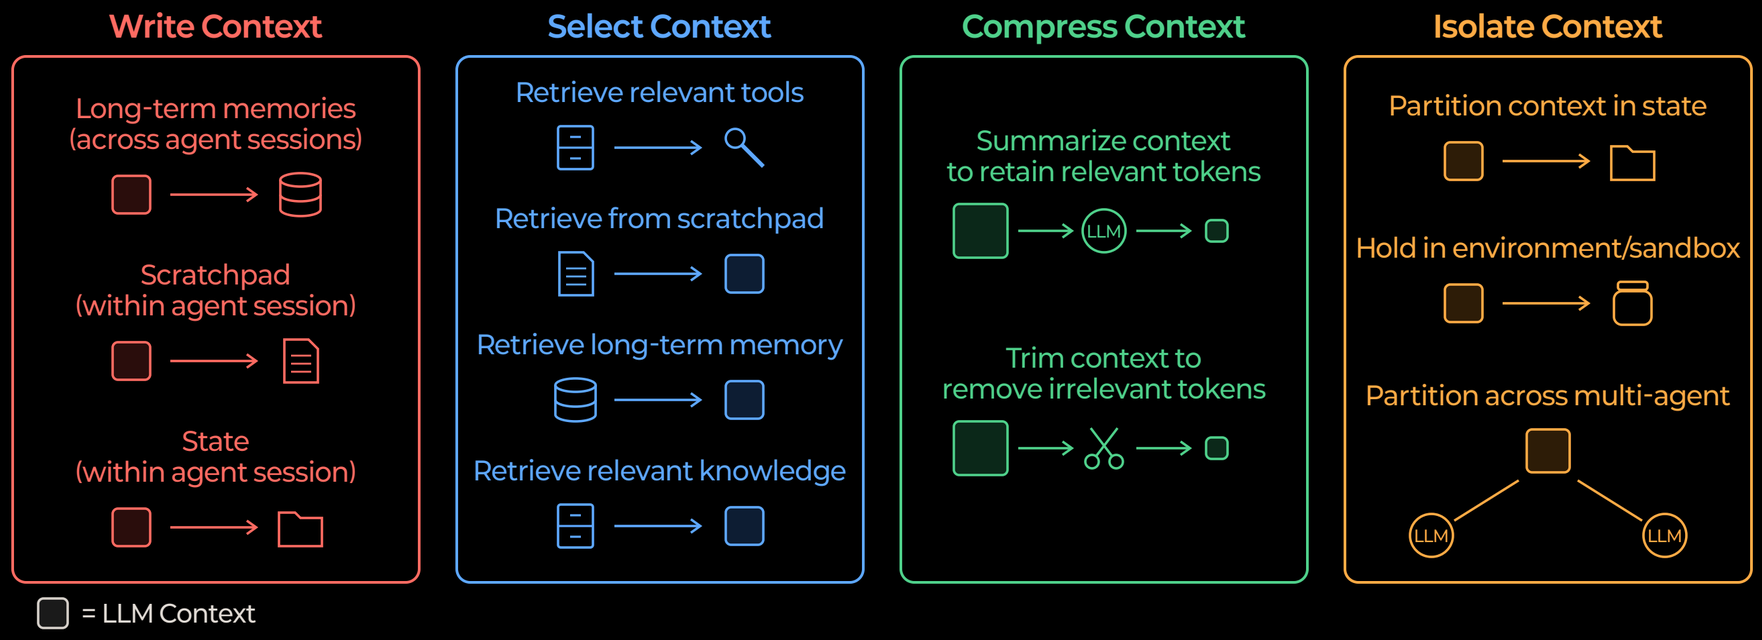
※ 프롬프트 엔지니어링(Prompt engineering): 한 번의 질문에 쓸 지시문을 잘 쓰는 일. 지시문은 창의 일부일 뿐이라, 창 전체를 다루도록 넓힌 것이 컨텍스트 엔지니어링이다.



왼쪽: 질문 한 번에 지시문만 작성 / 오른쪽: 매번 후보 정보 중 필요한 것만 선별(Curation)

컨텍스트 관리(Context management)

컨텍스트 관리: 창을 가볍게 유지하기 위해 정보를 다루는 네 가지 방법.



Write·Select·Compress·Isolate 네 가지 방법과 세부 기법

쓰기(Write): 중요한 정보를 파일에 적어 두고 필요할 때 다시 읽는다 → CLAUDE.md, 메모 파일

고르기(Select): 지금 작업에 필요한 정보만 골라 창에 불러온다 → @파일 지정, 스킬

줄이기(Compress): 쌓인 대화를 요약하거나 필요 없는 기록을 지운다 → /compact, /clear

나누기(Isolate): 큰 조사는 별도 창에서 처리하고 결과 요약만 받는다 → 서브에이전트