KEI

토큰과 컨텍스트

토큰 Token

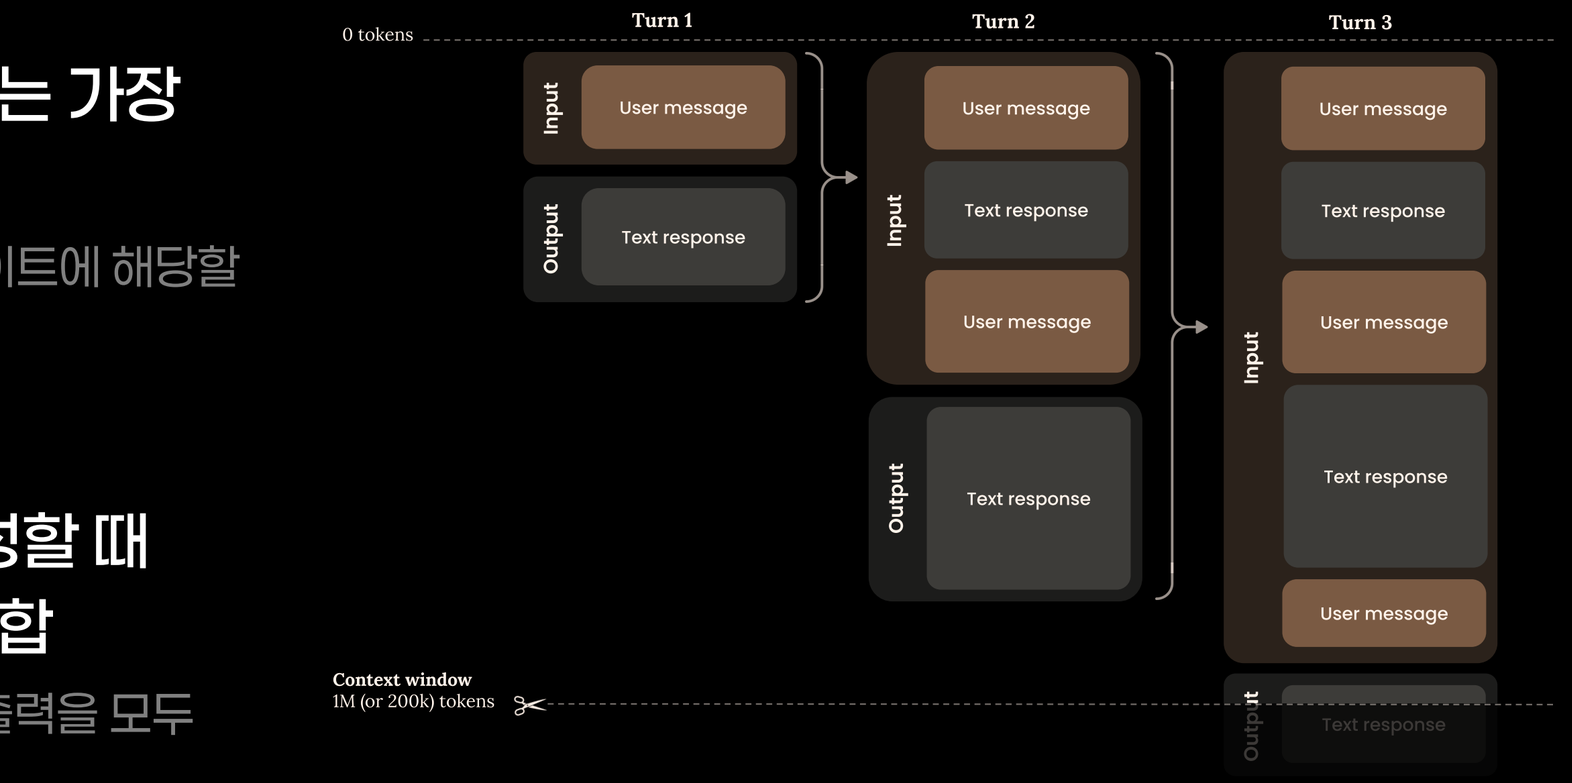
언어 모델이 처리하는 가장 작은 단위

단어, 단어 조각, 글자, 바이트에 해당할 수 있다

컨텍스트 Context

LLM이 출력을 생성할 때 참조하는 토큰의 집합

입력과 지금까지 생성한 출력을 모두 포함한다



KEI

컨텍스트 창

컨텍스트 창 Context window

모델이 새 텍스트를 생성할 때 참조할 수 있는 텍스트의 양

모델의 작업 기억

한계 Limit

200K 또는 1M 토큰

입력 + 출력의 합 기준

컨텍스트 부패 Context rot

토큰이 늘수록 정확도와 회상이 떨어지는 현상

